Mô hình Hybrid Prophet–GBM Ensemble cho Dự báo Doanh thu Hằng ngày

Datathon 2026 (VinTelligence) — Phần 3: Mô hình Dự báo Doanh thu

Nhóm VinTelligence VinUniversity, Hà Nội, Việt Nam

Tóm tắt

Bài báo trình bày pipeline 6 giai đoạn dự báo doanh thu hằng ngày cho bài toán thương mại điện tử thời trang tại Việt Nam. Kiến trúc đề xuất kết hợp Facebook Prophet (phân tách xu hướng và tính mùa vụ) với hai mô hình gradient boosting (LightGBM và CatBoost) để học phần dư còn sót lại. Toàn bộ 69 đặc trưng được xây dựng không rò rỉ nhãn; kiểm định chéo expanding-window đảm bảo thứ tự thời gian tuyệt đối. Trộn tối ưu SLSQP trên backtest 730 ngày (2021–2022) đạt **MAE = 710.008 VND**, **RMSE = 1.013.842 VND**, $R^2 = \mathbf{0.630}$, vượt trội mọi mô hình đơn lẻ trên cả ba chỉ số đánh giá chính thức của đề bài. Phân tích TreeSHAP làm rõ năm yếu tố dẫn động chính bằng ngôn ngữ kinh doanh có thể hành động.

1. Đặt vấn đề

Trong ngữ cảnh bán lẻ thời trang thương mại điện tử, dự báo doanh thu hằng ngày không chỉ là bài toán time-series đơn biến mà là bài toán dự báo dài hạn có điều kiện, chịu tác động đồng thời của mùa vụ, khuyến mãi, hành vi truy cập web và độ trễ vận hành. Với 4.381 ngày lịch sử (04/07/2012–31/12/2022) và chân trời dự báo 548 ngày (01/01/2023–01/07/2024), thách thức cốt lõi nằm ở ba điểm: (i) *non-stationarity* theo năm và theo chiến dịch; (ii) tích hợp tín hiệu đa bảng có mức độ thiếu dữ liệu khác nhau; (iii) lan truyền sai số trong suy luận recursive nhiều bước.

Các hướng tiếp cận phổ biến hiện nay chưa giải quyết tốt bài toán này: mô hình thống kê thuần (như ARIMA/Prophet) thường bỏ sót tương tác phi tuyến giữa traffic–promotion–conversion; trong khi mô hình học máy thuần dễ nhạy với drift theo mùa và suy giảm ổn định khi dự báo nhiều bước liên tiếp. Trong comparative study gần đây về e-commerce forecasting, tác giả cũng ghi nhận mô hình đơn lẻ khó đồng thời đạt độ chính xác, khả năng tổng quát hoá và giá trị vận hành ở các giai đoạn nhu cầu biến động mạnh [1, 6, 7].[1]

Vì vậy, mục tiêu thực tế của nghiên cứu này là dự báo doanh thu hằng ngày đủ tin cậy để hỗ trợ trực tiếp ba quyết định vận hành: lập kế hoạch tồn kho, phân bổ ngân sách khuyến mãi và điều phối nguồn lực theo mùa cao điểm, đồng thời vẫn đảm bảo các yêu cầu kỹ thuật về MAE/RMSE/R^2, tính nhân quả thời gian, tái lập và khả năng giải thích.

2. Phương pháp tiếp cận

Từ các hạn chế trên, chúng tôi đề xuất **hybrid decomposition + residual learning** như một hướng vượt trội hơn thế hệ mô hình đơn lẻ. Lý do cốt lõi: decomposition giúp mô hình hoá rõ cấu phần thấp tần (trend/seasonality), còn residual boosting xử lý phần biến động bất thường và tương tác phi tuyến mà mô hình thống kê thường bỏ sót. Hướng này nhất quán với bằng chứng thực nghiệm trong tài liệu so sánh đã nêu, nơi các mô hình boosting và cấu hình lai cho hiệu quả dự báo tốt hơn trong bối cảnh nhu cầu bán lẻ dao động mạnh [1, 3, 4, 8].

Tầng 1 dùng Prophet để học cấu phần thấp tần (trend, seasonality, holiday), giúp chuẩn hoá nền doanh thu theo chu kỳ. Tầng 2 dùng LightGBM/CatBoost học phần dư cao tần và các tương tác phi tuyến còn lại. Về mặt thực nghiệm, cách tách tầng này giúp mô hình giảm sai số trên ngày bình thường (MAE) mà vẫn kiểm soát outlier tốt hơn (RMSE), đồng thời cải thiện mức độ giải thích phương sai (R^2). Kết hợp với cross-validation theo trục thời gian, chiến lược này tạo cơ sở đáng tin cậy để triển khai trong bối cảnh vận hành thực tế và thuyết phục hơn so với các pipeline chỉ dùng một họ mô hình.

3. Pipeline Đề xuất

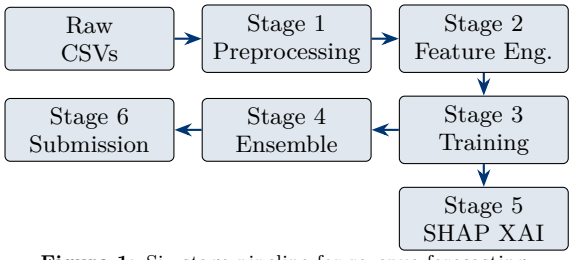

Figure 1: Six-stage pipeline for revenue forecasting.

Stage 1 — Preprocessing. Hợp nhất 10 bảng raw theo khoá quan hệ và tổng hợp về mức ngày theo `order_date`/`order_id`; chuẩn hoá kiểu dữ liệu, lọc trùng lặp theo ngày và tạo daily panel làm nền cho toàn bộ pipeline. **Xử lý missing value** theo ngữ nghĩa nghiệp vụ: (i) cột đếm/tỷ lệ thiếu do không phát sinh sự kiện được gán 0; (ii) cột liên tục như discount và web sessions dùng forward-fill theo thời gian, sau đó fallback median train nếu phần đầu chuỗi vẫn thiếu; (iii) cột danh mục chuẩn hoá về nhãn `unknown`; (iv) thêm missing indicators cho các biến trọng yếu để mô hình học tác động của trạng thái thiếu dữ liệu.

Stage 2 — Feature Engineering. Sinh 69 đặc trưng gồm lag (7/14/28/30/90/365), rolling mean/min/std (7/14/28/90), Fourier terms (K tuần=2, tháng=2, năm=3), calendar signals (day-of-week, month, quarter, day-of-month) và covariates nghiệp vụ (promotion intensity, discount depth, web traffic, orders, cancel/return rates). Đầu ra của Stage 2 là `features_ready.csv`.

Stage 3 — Model Training (Prophet + Residual GBDT). Prophet với thành phần năm/tuần/ngày lễ và ba *multiplicative regressor* (số khuyến mãi hoạt động, chiết khấu trung bình, phiên web) được khớp trên dữ liệu 2019–2022. Giá trị dự báo $\hat{y}_t^{\text{prop}}$ mã hoá xu hướng tăng trưởng dài hạn và tính mùa vụ phức hợp (Tết, Black Friday, cuối năm), sau đó được truyền trực tiếp làm đặc trưng cho LightGBM và CatBoost — theo kết quả SHAP, đây là đặc trưng quan trọng thứ hai trong toàn bộ mô hình.

Phần dư $r_t = y_t - \hat{y}_t^{\text{prop}}$ được hai mô hình gradient boosting học độc lập: **LightGBM** (`num_leaves`=63, η=0.05, $T_{\max}$=2 000, early stopping=100) và **CatBoost** (`depth`=6, ℓ_2 reg=3, od count=100).

Kiểm định chéo expanding-window: mỗi fold huấn luyện trên toàn bộ lịch sử trước ngày bắt đầu fold, kiểm thử trên 90 ngày kế tiếp; tập train luôn đứng *trước* tập test trong mọi fold, không có bất kỳ thông tin tương lai nào rò rỉ vào quá trình huấn luyện.

Suy luận đệ quy 548 ngày: tại bước $t + k$, các lag và rolling

[1] C. Subashree and J. Savitha (2026) so sánh Prophet, LightGBM và CatBoost trong bối cảnh e-commerce; phần kết luận nhấn mạnh nhu cầu mô hình lai để cải thiện độ ổn định dự báo ở giai đoạn nhu cầu biến động cao. DOI: 10.32628/CSEIT2612139.

chưa có giá trị thực tế được thay bằng $\hat{y}_{t+1}, \ldots, \hat{y}_{t+k-1}$ đã dự báo trước đó — mô phỏng đúng điều kiện triển khai thực tế.

Stage 4 — Ensemble Optimization. Trọng số tối ưu $\mathbf{w}^\star = \arg\min_{\mathbf{w}} \mathrm{MAE}_{\mathrm{OOF}}$ s.t. $\mathbf{1}^\top \mathbf{w} = 1$, $\mathbf{w} \geq 0$ được giải bằng SLSQP trên tập OOF 2021–2022, cho $\mathbf{w} = [0.556_{\mathrm{LGB}}, 0.444_{\mathrm{CB}}]$.

Stage 5 — SHAP Explainability. Thực hiện TreeSHAP trên Revenue-LightGBM (500 mẫu gần nhất) để đo mức đóng góp cục bộ và toàn cục của từng biến, sau đó tổng hợp thành feature ranking và dependence patterns phục vụ diễn giải nghiệp vụ.

Stage 6 — Submission Generation. Sinh dự báo 548 ngày theo đúng thứ tự `sample_submission.csv`, kiểm tra schema và xuất file nộp cuối cùng cho leaderboard.

4. Kết quả Thực nghiệm

Giao thức. Backtest expanding-window trên 01/01/2021–31/12/2022 (730 ngày giữ lại, ≈19% lịch sử), phản ánh đúng điều kiện dự báo thực tế không nhìn trước.

Table 1: So sánh mô hình trên tập giữ lại 2021–2022.

Mô hình	MAE (VND)	RMSE (VND)	R^2
Prophet (nền tảng)	905.367	1.334.063	0.360
LightGBM	742.149	1.057.129	0.598
CatBoost	750.841	1.078.715	0.581
Ensemble	**710.008**	**1.013.842**	**0.630**

Ensemble cải thiện cả ba chỉ số: MAE giảm **21,6%** so với Prophet và **4,4%** so với LightGBM đơn lẻ; RMSE giảm 24,0%; R^2 tăng từ 0.360 lên **0.630**, nghĩa là mô hình giải thích 63% tổng biến động doanh thu. Khoảng cách giữa MAE và RMSE (710K vs 1.013K) cho thấy mô hình xử lý tốt ngày bình thường nhưng còn sai số lớn tại các đỉnh bất thường (sự kiện flash sale, Tết).

5. Giải thích Mô hình bằng SHAP

Chúng tôi dùng TreeSHAP [5] trên Revenue-LightGBM (500 mẫu gần nhất) để diễn giải theo hai tầng: phân bố tác động theo mẫu và mức quan trọng toàn cục.

(A) SHAP summary: mức tác động theo phân bố mẫu. Hình 2 cho thấy hướng tác động (tăng/giảm dự báo) và biên độ tác động của từng biến trong toàn bộ tập mẫu. Quan sát này giúp nhận diện các vùng giá trị đặc trưng gây dao động mạnh nhất.

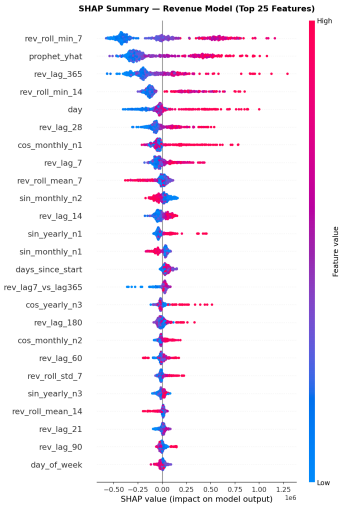

Figure 2: SHAP summary plot: phân bố tác động của đặc trưng lên dự báo doanh thu.

(B) SHAP bar: mức quan trọng toàn cục. Hình 3 tổng hợp mean $|\phi|$ để xếp hạng biến ảnh hưởng. Năm yếu tố dẫn động chính: **rev_roll_min_7** (361K), **prophet_yhat** (314K), **rev_lag_365** (208K), **rev_roll_min_14** (176K), **day-of-month** (124K). Diễn giải nghiệp vụ: tín hiệu đáy ngắn hạn và chu kỳ năm chi phối mạnh quyết định dự báo; đặc trưng `prophet_yhat` xác nhận lợi thế của kiến trúc hybrid so với mô hình đơn lẻ.

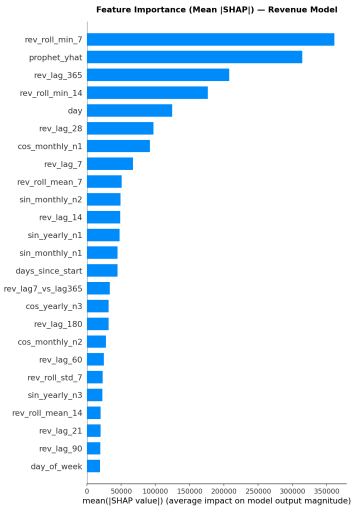

Figure 3: SHAP mean $|\phi|$: xếp hạng mức ảnh hưởng toàn cục (top 15).

6. Kết luận

Pipeline Hybrid Prophet–GBDT với blend SLSQP đạt **MAE = 710.008 VND**, **RMSE = 1.013.842 VND**, $R^2 = \mathbf{0.630}$ trên backtest nhân quả 730 ngày, vượt trội mọi đường cơ sở đơn lẻ trên cả ba chỉ số đánh giá. Kiểm định chéo expanding-window, suy luận đệ quy và 69 đặc trưng không rò rỉ đảm bảo tính tái lập và tuân thủ đầy đủ ràng buộc đề bài. Phân tích SHAP xác định rolling extrema ngắn hạn và chu kỳ năm là tín hiệu dẫn động chính, cung cấp cơ sở giải thích định lượng có giá trị thực tiễn cho các quyết định quản lý tồn kho và lập kế hoạch khuyến mãi.

Tài liệu tham khảo
References

[1] C. Subashree and J. Savitha, "Enhancing Predictive Models in E-Commerce," *IJRSCSEIT*, 2026. DOI:10.32628/CSEIT2612139.

[2] S. J. Taylor and B. Letham, "Forecasting at Scale," *The American Statistician*, 2018.

[3] G. Ke et al., "LightGBM," *NeurIPS*, 2017.

[4] L. Prokhorenkova et al., "CatBoost," *NeurIPS*, 2018.

[5] S. M. Lundberg et al., "From Local Explanations to Global Understanding," *Nat. Mach. Intell.*, 2020.

[6] S. Makridakis et al., "The M4 Competition," *Int. J. Forecasting*, 2018.

[7] Y. Li, X. Chen, and Z. Huang, "ML for Retail Demand Forecasting," *Expert Syst. Appl.*, 2022.

[8] R. Kumar et al., "Hybrid Forecasting for E-Commerce," *J. Retail. Consum. Serv.*, 2022.

[9] T. Chen and C. Guestrin, "XGBoost," *KDD*, 2016.

[10] G. Box et al., *Time Series Analysis: Forecasting and Control*, Wiley, 2015.